

심민우

AI / ML Engineer

Email smw5626@gmail.com | Phone 010-6880-5626 | 생년월일 1996.02.15

Summary

- 한글 손글씨 OCR (TrOCR) — 실사용 학습데이터가 없는 제약 조건에서 Text Recognition 정확도 83% 달성, OCR 특허 등록(제 10-2876384 호).
- 문서 Document Layout Analysis 합성 증강 — 금융·공공·과학 low-resource 문서의 레이아웃 분포를 모델링·합성·자동 라벨링해 YOLOv13·RF-DETR 모두에서 비교 증강 방법론 중 가장 높은 mAP@50:95(DocLayNet 최대 +8.8%p). 해당 증강 방법 특허 등록(제 10-2899199 호).
- Data-Centric 데이터셋 최적화 — 최적화 8 만 장이 무작위 13 만 장 대비 mAP +0.21(0.64→0.85), 데이터 수량 40% 절감.

Core Competencies

OCR · VLM · Document AI TrOCR · Character-level Tokenizer · Document Layout Analysis(YOLOv13 · RF-DETR · DocLayNet)

학습 데이터 파이프라인 · 합성/증강 도메인 문서 합성 + 레이블 자동 생성 · 레이아웃 분포(KDE) 모델링 · 저자원(low-resource) 증강 전략 · 스캔/노이즈(Augraphy) augmentation · 합성 손글씨 데이터 생성

Data-Centric AI · 임베딩/인덱싱 임베딩(ResNet/CLIP)+FAISS 인덱싱·큐레이션 · Active Learning / Uncertainty Sampling · Semi-auto Labeling · 테스트케이스 · FP/FN 개선

Engineering Python · PyTorch · Hugging Face Transformers · OpenCV · Pillow · NumPy · pandas

Work Experience (총 경력 4년 2개월)

셀렉트스타 · AI 1팀 / AI Research Engineer

2024.05 ~ 재직 중 (2년 3개월)

한글 손글씨 멀티라인 OCR 모델 개발 (TrOCR)

2024.05–2024.12 (7개월)

성과 실사용 학습데이터가 없는 환경에서 Text Recognition Accuracy 83% 달성 · OCR 특허 등록(제10-2876384호)

- 실사용 데이터 800 장을 학습에 사용할 수 없어, 평가 셋으로만 사용해야하는 제약에서 오픈 데이터셋과 자체 합성 데이터로 TrOCR 기반 한글 멀티라인 recognition 모델 개발. 별도의 text-line detection 없이 전체 이미지에서 문자열을 직접 생성하는 End-to-End 구조를 적용해 detection 단계의 오류 전파 방지.
- 한글 손글씨 폰트 기반 합성데이터 생성기를 직접 구현해 자간·시작위치·줄 간격·폰트 분포를 학습데이터에 반영하고, 오픈 데이터셋→합성 손글씨의 단계별 학습 전략 설계.
- 한글 Character-level Tokenizer 를 활용/적용하여 비정상 문자열 생성 오류율 약 90% 감소.

기술 스택 Python · PyTorch · Hugging Face Transformers · TrOCR · Synthetic Data · OCR

금융·공공·과학 문서 Document Layout Analysis — 의미·구조 합성 증강

2025.06 ~ 2025.09 (3개월)

성과 저자원 도메인 문서 레이아웃 합성 증강 기법 설계 · YOLOv13·RF-DETR 모두에서 비교 증강 방법론 중 최고 mAP@50:95 달성

- 민감정보로 수집·외부 라벨링이 어려운 금융·공공·과학 문서의 저자원(도메인별 500 장 규모) 한계를, 문서의 레이아웃 요소를 분리하고 클래스별 위치·크기·개수 분포(KDE)를 모델링해 페이지를 재조합하는 합성 증강으로 해결.
- 요소 간 충돌·점유율 제약과 의미 유사도 기반 자산 선택으로 실제 문서의 공간/의미 분포를 반영한 레이아웃으로 자동 생성·자동 라벨링하고, 스캔·압축·노이즈 열화를 모사하는 Augraphy 와 보완적으로 결합하여 성능 향상

- YOLOv13-RF-DETR 두 아키텍처, 내부 데이터셋과 공개 DocLayNet 전 도메인에서 baseline-전통 증강(cutmix/mixup 등) 비교 증강 방법론 중 가장 높은 mAP@50:95 를 달성(DocLayNet 최대 +8.8%p).
- 특허 등록 (문서레이아웃 학습을 위한 합성데이터의 생성 방법, 제 10-2899199 호)

기술 스택 *Python · PyTorch · YOLOv13 · RF-DETR · Document Layout Analysis · DocLayNet · Synthetic Data Augmentation*

인물 사진 기반 개인화 캐릭터 생성 AI 파이프라인 (PoC)

2025.03 ~ 2025.06 (3개월)

성과 VLM 기반 5단계 End-to-End 파이프라인 단독 설계·구현 · 검수 통과율 50%p 개선(35%→85%)

- 인물→캐릭터 변환(image-to-image) 시 스타일 변환이 적용되지 않는 문제가 있어, 인물 사진에서 핵심 컨텍스트(피부·헤어·의상·액세서리·포즈)만 구조화하여 추출 → 기존 캐릭터 에셋(이미지)에 적용하는 아키텍처로 해결(캐릭터 아이덴티티 보존).
- 사진 → 스타일 추출 → 변환 → 배경 제거 → 검수 5 단계 파이프라인을 구현. 이미지 변환 성공률 98% 달성.
- 그린스크린(#00FF00) 생성 + OpenCV 크로마키 마스킹으로 별도 세그멘테이션 모델 없이 투명 배경 처리(건당 약 15 초 이내), 로컬 알파 채널 휴리스틱 + LLM-as-a-Judge(7 개 기준) 2 단계 품질 게이트를 통해 서비스 안정성 확보.

기술 스택 *Python · Google Gemini · Pydantic · OpenCV · NumPy · Pillow · Prompt Engineering · LLM-as-a-Judge*

독자 파운데이션 모델 프로젝트 (SKT 컨소시엄)— 멀티모달 학습 데이터셋 구축 (Reasoning · QA)

2025.08

~ 2025.12 (4개월)

성과 Reasoning 구조화 · QA 데이터 생성 파이프라인 구축 · 데이터 검수 통과율 58% → 86% 향상

- 파운데이션 모델 학습용 Reasoning 구조화 및 QA 데이터 생성을 담당, 관련 논문의 고품질 데이터 생성 방법론을 적용하여 생성 데이터의 품질을 끌어올림.
- 데이터 평가 루브릭 정의를 통한 1 차 모델 검수 진행 단계를 추가하여 대량 생성 과정에서도 일관된 품질을 유지, 데이터 휴먼 검수 통과율을 58%에서 86%까지 향상.

기술 스택 *Python · PyTorch · Hugging Face · Reasoning · QA Data Generation · 멀티모달 데이터셋 구축*

정찰용 무인수상정 체계 프로젝트— 3D 객체 생성 / Image Composition

2025.09 ~ 2026.07 (10개월)

성과 TRELIS 3D 객체화 + 해상도 정합 합성 파이프라인으로 합성 데이터 10,000건 생성 · 정찰용 무인수상정 체계 대상

- 북한 수상정처럼 추론 대상이지만 현실적으로 수집이 불가능한 표적을, 소량의 실물 이미지와 공개 인터넷 이미지에서 확보한 뒤 TRELIS 로 3D 객체화하고 다양한 각도의 이미지를 캡처해 배경 이미지에 자연스럽게 합성.
- 합성 모델 출력과 원본 이미지의 해상도가 어긋나는 문제를, 원본에서 합성 모델 출력 해상도에 맞는 영역만 잘라내 합성한 뒤 원위치에 다시 붙여넣는 방식으로 해결해 이질감을 최소화.
- 배경·위치·스케일·조도 조건을 분해해 다양한 상황의 합성 데이터 총 10,000 건을 생성하고, 보안·컴플라이언스 제약 하에서 내부 활용 가능한 형태로 데이터 생성 파이프라인을 설계·운영.

기술 스택 *Python · Computer Vision · TRELIS · 3D Object Generation · Image Composition · Synthetic Data*

에이모(AIMMO) · 자율주행팀 / 연구원

2021.12 ~ 2023.10 (1년 11개월) (2023 상반기 성과우수자)

Data-Centric Object Detection 학습 데이터셋 최적화

2022.06~2023.02 (8개월)

성과 데이터 수량 약 40% 감소하며 mAP +0.21 향상(0.64→0.85) · 총 26만 장 데이터셋 구축 기여

- ISO 34503 기반 ODD 를 정의해 데이터셋 조건을 표준화하고 수집·레이블링 요구사항으로 연결, 날씨·조도·도로환경·객체 가림 정도를 변수로 통제된 Data-Centric 실험 7 건 수행.
- CLIP 기반 이미지 메타데이터 semi-auto labeling 으로 대량 분류를 가속하고, 100 개 이상 테스트 케이스와 FP/FN 분석으로 레이블링 가이드·데이터셋 기준 개선 루프를 운영. 데이터 최적화 성과를 고객사 PoC 및 대외 기술 검증 자료로 활용

기술 스택 *Python · PyTorch · YOLOv5 · CLIP · ISO 34503 · ODD*

Active Learning 기반 데이터 추출 시스템 개발

2022.02-2022.05 (3개월)

성과 데이터 수집 5일→2일 단축 · 정제 비용 약 50% 절감 · 전체 데이터 생산 효율 38% 향상

- 수집 단계에서 학습 무기여 데이터가 대량 저장되는 문제를, YOLOv5 기반 조건별 추출 시스템으로 1차 필터링해 저장·후처리 비용을 절감.
- Active Learning·Uncertainty Sampling으로 모델이 어려워하는 샘플을 우선 확보하고, 벡터 DB 유사도 검색으로 중복·유사 데이터를 제거해 다양성을 확보. 팀 세미나 후 기존 생산 프로세스에 도입.

기술 스택 Python · PyTorch · YOLOv5 · Active Learning · Uncertainty Sampling · Vector DB

임베딩 기반 데이터 큐레이션 툴 프로토타입 개발

2023.02-2023.05 (3개월)

성과 데이터 정제 작업 효율 30% 향상 · 고객사 PoC/계약 기여

- ResNet 임베딩 + FAISS 인덱싱으로 대량 이미지의 유사도·분포 탐색을 가속하고, FiftyOne 기반 시각화로 담당자·고객사가 데이터 품질을 직관적으로 확인하도록 프로토타입을 개발(정식 툴로 이관).

기술 스택 Python · ResNet · FAISS · FiftyOne

Education

인제대학교 · 전자IT기계자동차공학부 창의전자 전공 (학사)

2014.03 ~ 2021.02

- 2020 학년도 창의전자 학생회장 · 지역선도대학 현장실습생 선발(한국남동발전)

Training & Other Experience

- 한경국립대 강의 진행 — 「딥러닝/머신러닝 입문」(2025.08, 22h) · 「머신러닝/딥러닝 실전 트레이닝」(2026.01, 22h)
- 코드스테이츠 AI Bootcamp 2기 (2021.03~2021.09)
- 정보통신산업진흥원 「파이썬 활용 인공지능 이론과 실습」 160시간 수료(2020.11~2020.12) · 4차 산업혁명 스마트팜 아이디어 경진대회 우수상(2021.01)